



计算机视觉应用基础



第一部分：图像分割




任务或目标是什么？有什么应用？



医学图像



遥感图像




天文图像



自然图像

图像分割在计算机视觉中的地位？



图像分割难点以及处理？

难点：图像特征的如何组合难以表达？

处理：

1. 限制图像类型（医学MRI）
2. 引入目标先验知识（轮廓、颜色等）
3. 引入人为交互信息
4. 多幅图像联合



图像分割方法分类 (1)

1. 基于边缘的方法
2. 基于区域的方法
3. 综合边缘和区域的方法
4. 其它分割算法
 - a) 交互式分割
 - b) 基于学习的分割
 - c) 共分割 (Co-segmentation)




图像分割方法分类 (2)

1. 传统分割方法
 - a) 阈值分割 (OTUS)
 - b) 区域生长法 (分水岭分割)
 - c) 基于统计的分割算法: K-means图像分割及均值漂移分割等
2. 主动轮廓以及水平集分割算法
3. 图割方法 (拉普拉斯分割)
4. 深度学习分割 (FCN, SegNet, Deeplab等)

图像分割

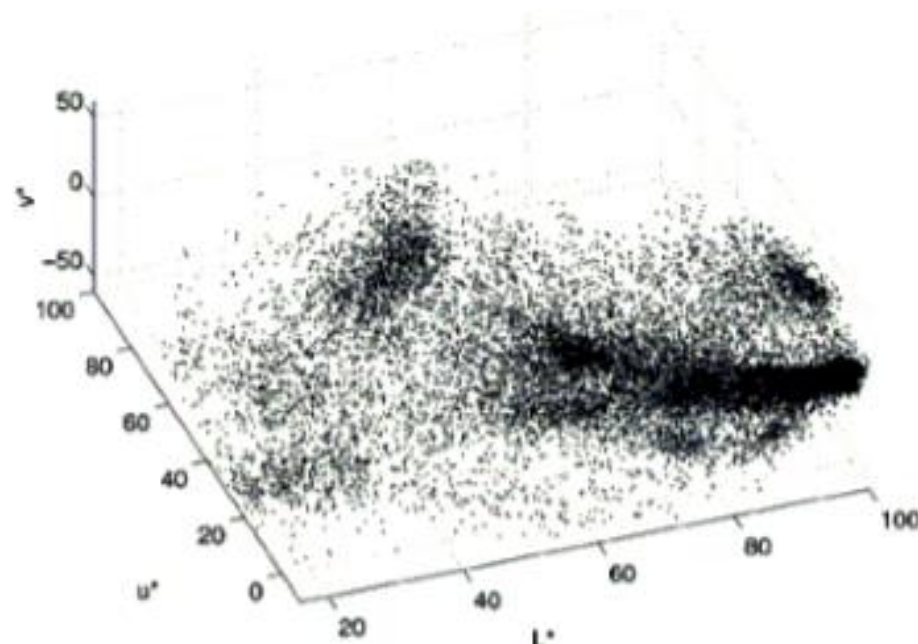
第一节：基于统计的图像分割



-  **基于统计的图像分割：K-means**
-  **K-means算法分析**
-  **实验结果分析**

基于聚类的图像分割基本思想

图像分割问题 \rightarrow 像素聚类问题



特征空间映射: RGB空间 \rightarrow Luv空间

需要解决的问题

(1) 每个像素的特征如何表达？

- 纹理特征：像素值、直方图特征、颜色矩、颜色相关图、Gabor特征等
- 描述子：SIFT、SURF、HoG、MSER、Brief、ORB、KAZE等

(2) 如何聚类？

- 采用机器学习中的聚类算法，如k-means、层次聚类等
- Mean-shift算法


聚类任务形式化表示

输入： 像素特征的集合 $\mathcal{D} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$

输出： 集合 \mathcal{D} 的一个划分, 即: $\mathcal{D} = \bigcup_{i=1}^k \mathcal{D}_i$

同时 $\mathcal{D}_i \cap \mathcal{D}_j = \emptyset, \forall i \neq j$

聚类任务形式化表示



空间划分示意图

聚类任务形式化表示

\mathcal{D} 中成员 $\mathcal{D}_1, \mathcal{D}_2, \dots, \mathcal{D}_k$ 叫做**类或者簇**(cluster), 每个类都是通过一些 “特征” 来描述的:

- 通过**类中心**或者**类的边界点**来表示;
- 使用聚类树采用**图形化方式**来表示。

K-means聚类：定义

- (1) K-means聚类算法是典型的**基于距离的聚类算法**
- (2) 最终目标：**得到紧凑且独立的簇**
- (3) **采用均方误差最小化**，学习问题

定义：基于距离的聚类算法，采用距离作为相似性的评价指标，即认为两个对象的距离越近，其相似度就越大。

K-means聚类：定义

- (1) K-means聚类算法是典型的**基于距离的聚类算法**
- (2) 最终目标：**得到紧凑且独立的簇**
- (3) **采用均方误差最小化**，学习问题

$$\{\mu_j^*, \mathcal{D}_j^*\}_{j=1}^k = \arg \min_{\{\mu_j, \mathcal{D}_j\}_{j=1}^k} \sum_{j=1}^k \sum_{\mathbf{x}_i \in \mathcal{D}_j} \|\mathbf{x}_i - \mu_j\|_2^2$$

K-means聚类：优化（交替迭代优化）

示例： $x, y, z = \arg \min_{x, y, z} f(x, y, z)$

列方程求解

$$\begin{cases} \frac{\partial f(x, y, z)}{\partial x} = 0 \\ \frac{\partial f(x, y, z)}{\partial y} = 0 \\ \frac{\partial f(x, y, z)}{\partial z} = 0 \end{cases}$$

方程组
求解难
难以
求导

问题
分解

交替
迭代

$$\begin{aligned} \textcircled{1} \quad & x = \arg \min_x f(x, y^*, z^*) \\ \textcircled{2} \quad & y = \arg \min_y f(x^*, y, z^*) \\ \textcircled{3} \quad & z = \arg \min_z f(x^*, y^*, z) \end{aligned}$$

① → ② → ③ → ① → ② → ...

K-means聚类：优化

交替迭代优化

$$\{\mu_j^*, \mathcal{D}_j^*\}_{j=1}^k = \arg \min_{\{\mu_j, \mathcal{D}_j\}_{j=1}^k} \sum_{j=1}^k \sum_{\mathbf{x}_i \in \mathcal{D}_j} \|\mathbf{x}_i - \mu_j\|_2^2$$

(1) 交替迭代什么

$$\{\mu_j\}_{j=1}^k \rightarrow \{\mathcal{D}_j\}_{j=1}^k \rightarrow \{\mu_j\}_{j=1}^k \rightarrow \{\mathcal{D}_j\}_{j=1}^k \rightarrow \dots$$

(2) 具体如何交替迭代

1. 固定聚类中心 $\{\mu_j\}_{j=1}^k$ 优化划分 $\{\mathcal{D}_j\}_{j=1}^k$



每个样本寻找最近的聚类中心

2. 固定划分 $\{\mathcal{D}_j\}_{j=1}^k$ 优化聚类中心 $\{\mu_j\}_{j=1}^k$



对每个划分求解均值

K-means聚类：优化

交替迭代优化

$$\{\mu_j^*, \mathcal{D}_j^*\}_{j=1}^k = \arg \min_{\{\mu_j, \mathcal{D}_j\}_{j=1}^k} \sum_{j=1}^k \sum_{\mathbf{x}_i \in \mathcal{D}_j} \|\mathbf{x}_i - \mu_j\|_2^2$$

1. 固定聚类中心 $\{\mu_j\}_{j=1}^k$ ，优化划分 $\{\mathcal{D}_j\}_{j=1}^k$

$$d_1 = \|\mathbf{x}_i - \mu_1\|_2^2$$

$$d_2 = \|\mathbf{x}_i - \mu_2\|_2^2$$

.....

$$d_k = \|\mathbf{x}_i - \mu_k\|_2^2$$



$$j^* = \arg \min_j d_j$$



\mathbf{x}_i 归入第 j^* 个簇

K-means聚类：优化

交替迭代优化

$$\{\mu_j^*, \mathcal{D}_j^*\}_{j=1}^k = \arg \min_{\{\mu_j, \mathcal{D}_j\}_{j=1}^k} \sum_{j=1}^k \sum_{\mathbf{x}_i \in \mathcal{D}_j} \|\mathbf{x}_i - \mu_j\|_2^2$$

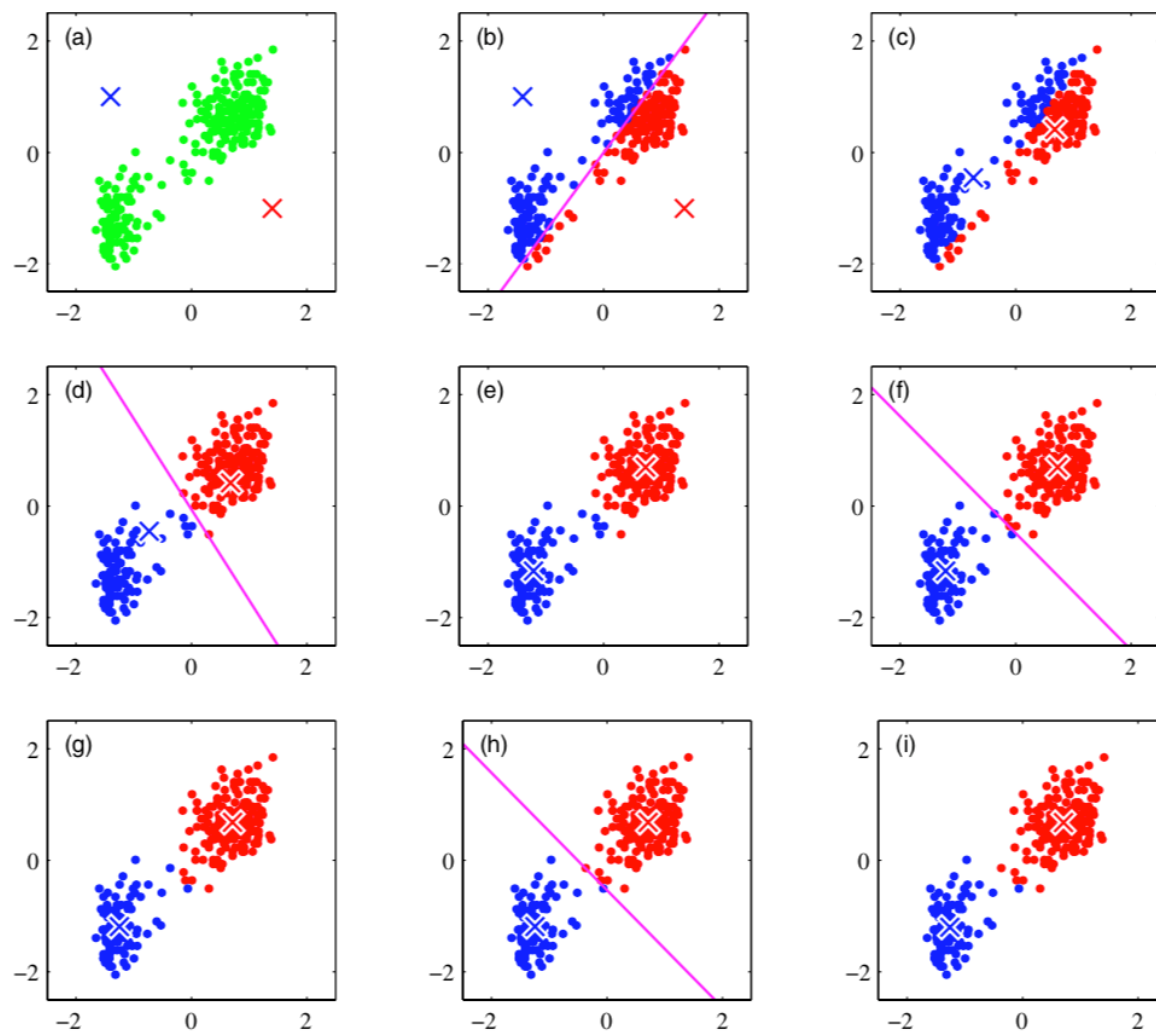
2. 固定划分 $\{\mathcal{D}_j\}_{j=1}^k$ ，优化聚类中心 $\{\mu_j\}_{j=1}^k$

$$\mu_j^* = \arg \min_{\mu_j} \sum_{\mathbf{x}_i \in \mathcal{D}_j} \|\mathbf{x}_i - \mu_j\|_2^2 \quad \Rightarrow \quad \mu_j = \frac{\sum_{\mathbf{x}_i \in \mathcal{D}_j} \mathbf{x}_i}{|\mathcal{D}_j|}$$

K-means聚类：算法

1. 初始化聚类中心 $\{\mu_j\}_{j=1}^k$ 可以随机选取几个样本作为聚类中心
2. **do**
3. 基于聚类中心 $\{\mu_j\}_{j=1}^k$, 计算划分 $\{\mathcal{D}_j\}_{j=1}^k$
4. 基于划分 $\{\mathcal{D}_j\}_{j=1}^k$, 计算聚类中心 $\{\mu_j\}_{j=1}^k$
5. **until**
6. **return** 聚类中心 $\{\mu_j\}_{j=1}^k$ 和划分结果 $\{\mathcal{D}_j\}_{j=1}^k$

K-means聚类：示例





基于统计的图像分割：K-means



K-means算法分析



实验结果分析

K-means聚类：细节分析

(1) 初始化：

- 从划分开始：随机选择一个划分，计算每类中心，以此作为初始点。
- 从聚类中心开始：随机选择几个样本（前 k 个样本）。
- 经验法**：凭经验选择初始代表点，主要根据问题相关性。
- 密度法**：以每个样本为中心，在一个球形区域内估计样本密度，类似Parzen窗方法，逐步地将数据划分至不同的密度区域。
- 中心分解方法**：先将所有数据看成一个聚类，计算聚类中心，然后寻找与该中心最远的点，划入一部分数据点至该最远点所在的区域；对剩下的数据，以此类推（参考K-means++算法）。

K-means聚类：细节分析


(2) 聚类个数确定：

—经验法：凭经验选择聚类个数，三

—验证法：根据不同“聚类个数”自

问题1：随着聚类个数的增加，目标

问题2：可不可以用一般的“交叉验



K-means聚类：细节分析

(3) 算法退出判别：

- 迭代次数**：达到预先设置的最大迭代次数。
- 聚类中心差异**：根据前后两次聚类中心的差异，小于某阈值。

(4) 大数据：

- elkan K-means

K-means聚类：细节分析

(3) 算法退出判别：

- 迭代次数：达到预先设置的最大迭代次数。
- 聚类中心差异：根据前后两次聚类中心的差异，小于某阈值。

(4) 大数据：

- elkan K-means
- Mini Batch K-Means

K-means聚类：优缺点分析

(1) 优点：

- 简单、快速（是解决聚类问题的经典算法）。
- 对处理大数据集，该算法仍可保持其高效率。
- 对于密集簇，聚类效果很好。

(2) 缺点：


- 必须事先给定簇的个数，且对初始值较为敏感（局部最优）。
- 不适合于发现非凸曲面的簇以及大小相差很大的簇。
- 对噪声、孤立数据点、野点很敏感。
- 对于类别不平衡的数据，处理不理想。

K-means聚类：优缺点分析

(1) 不适用于发现非凸曲面的簇以及大小相差很大的簇

解决方法：

- 使用新的度量函数
- 引入“流形学习”技术，使用**谱聚类**



K-means聚类：优缺点分析

(2) 对噪声、孤立数据点、野点很敏感。

解决方法：

- 使用鲁棒的度量函数
- 使用模糊K-means方法
- 使用K-Medoids聚类技术
- 引入“流形学习”技术，使用**谱聚类**

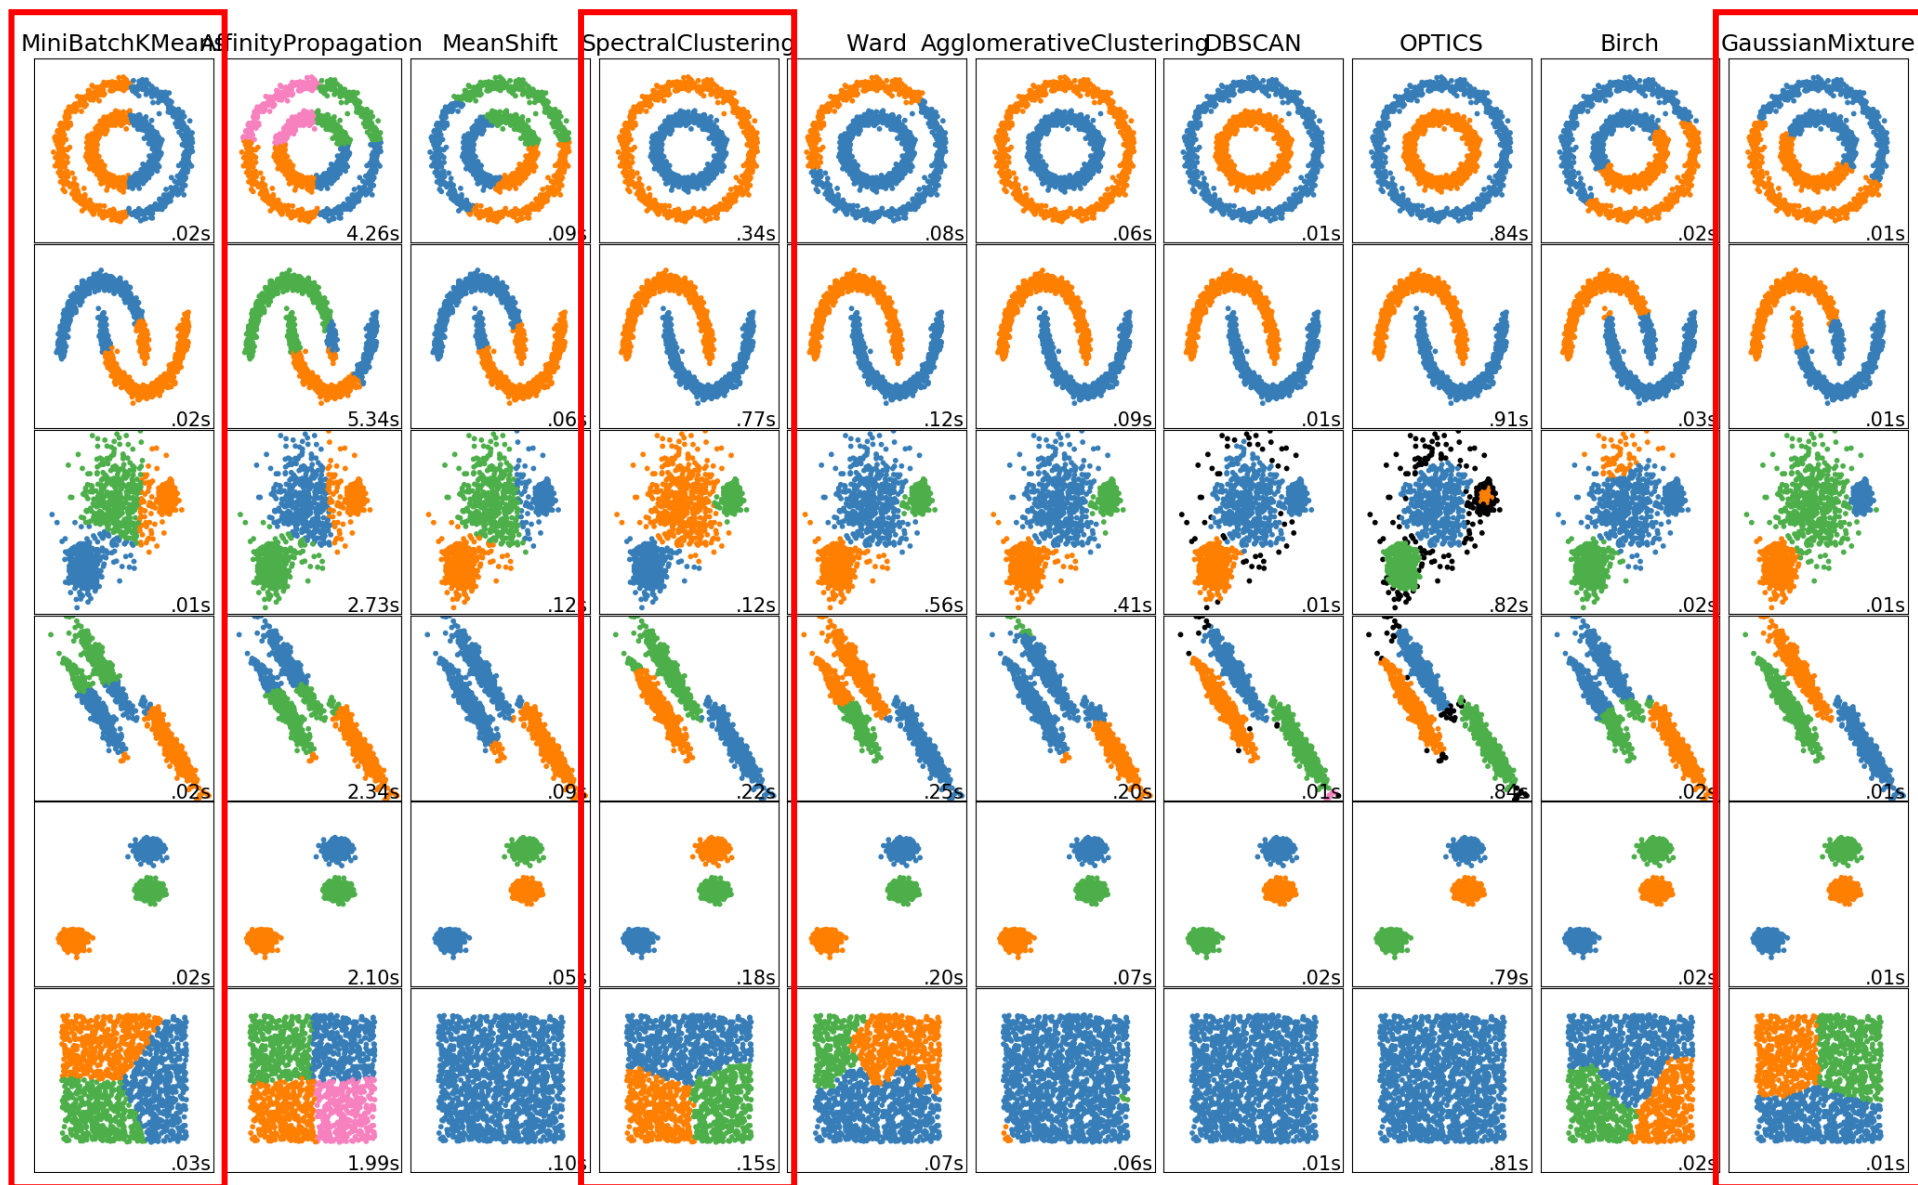
K-means聚类：优缺点分析




(3) 对于类别不平衡的数据，处理不理想

解决方法：


- 使用多高斯聚类技术
- 引入“流形学习”技术，使用**谱聚类**

K-means优缺点分析



-  基于统计的图像分割：K-means
-  K-means算法分析
-  实验结果分析

K-means图像分割结果 不同的空间加权, 固定聚类中心个数=3




空间加权 = 0




空间加权 = 0.15

K-means图像分割结果 不同的聚类中心个数，固定空间加权=0



聚类中心个数 = 3



聚类中心个数 = 4

作业1：自己实现k-means算法。

作业2：证明，随着聚类个数增加，聚类目标函数值不增加？

作业3（选做）：交替迭代算法优化“非负矩阵分解”问题，并用代码实现。

问题：参考资料：<https://zhuanlan.zhihu.com/p/27460660>

目的：加深对交替迭代算法理解。

感谢聆听！
Thanks for Listening

